Tratamiento de datos y storytelling: Natalidad en Argentina (2012–2024)

Informe profesional del proyecto «Dashboard de Natalidad» · Metodología de datos y narrativa analítica

1. Propósito y audiencia

Este informe documenta dos cosas: **cómo se trataron los datos** (de la fuente original al indicador que se muestra en pantalla) y **cómo se construyó la historia** que el dashboard cuenta con ellos. Está pensado para tres públicos: quien evalúa el proyecto, quien lo va a mantener y quien lo va a presentar.

La pregunta que organiza todo el trabajo es:

> ¿Cómo cambió la natalidad en Argentina entre 2012 y 2024, y qué contexto demográfico, económico y de políticas públicas la rodea?

2. Resumen ejecutivo

- El proyecto integra **ocho archivos de datos abiertos** de cuatro dominios (población, economía, salud y percepción social) mediante tres notebooks de Jupyter y una aplicación Streamlit.
- El tratamiento sigue un flujo de cinco etapas: ingesta, limpieza, transformación, exportación a archivos procesados y consumo en el dashboard. La app lee solo datos procesados, lo que separa el análisis de la presentación.
- La narración se organiza en **ocho capítulos** que van de un dato central (nacimientos en el año pico frente al último año) a la desigualdad territorial, la edad de las madres, el contexto económico y la evidencia disponible sobre posibles causas.
- Se estudian **cuatro hitos de política de salud sexual y reproductiva** (2014, 2015, 2017 y 2020) con un método común: índice base 100 en el año del hito y comparación con un grupo de referencia.
- La regla narrativa del proyecto es distinguir lo que los datos **muestran** de lo que **no pueden probar**. Todas las comparaciones son descriptivas, y el dashboard lo dice explícitamente en notas y en un bloque de lectura final.

Parte I · Tratamiento de datos

3. Flujo general de datos

Etapa	Qué ocurre	Dónde
1. Ingesta	Lectura de CSV originales con pandas, incluyendo separadores y codificaciones propias de cada fuente	Notebooks
2. Limpieza	Selección de columnas útiles, filtro por período, descarte de columnas vacías, conversión de fechas	Notebooks
3. Transformación	Agrupaciones, acumulados, variaciones porcentuales, tablas cruzadas y ordenamiento de categorías	Notebooks
4. Exportación	Escritura de tablas listas para graficar en `DATA_PROCESADA/`	Notebooks
5. Consumo	Lectura de los archivos procesados, normalización de nombres y cálculo de indicadores de presentación	`app.py`

El principio de diseño es que **los notebooks preparan y la app muestra**. Así, si cambia una fuente, solo se vuelve a ejecutar el notebook correspondiente y la app se actualiza sin tocar el código de visualización.

4. Inventario de fuentes

Dominio	Contenido	Volumen	Uso en el proyecto
Población	Nacimientos por edad de la madre, provincia y año (2012–2024)	2.496 registros	Serie provincial, composición por edad materna, hitos
Población	Nacimientos por departamento y año	6.669 registros	Análisis exploratorio de totales anuales en el notebook

Dominio	Contenido	Volumen	Uso en el proyecto
Población	Población identificada por provincia, sexo, edad quinquenal, nacionalidad y país de nacimiento (agosto 2024)	3.197 registros	Pirámide poblacional y tasas aproximadas
Población	Encuesta de percepción social (varias olas)	9.232 registros, 118 variables	Indicadores de actitud, material complementario
Economía	Salario mínimo vital y móvil (mensual, diario, por hora)	748 registros	Contexto económico
Economía	Inflación (serie porcentual histórica)	1.003 registros	Contexto económico
Salud	Inversión pública por objetivo socioeconómico	195 registros desde 2012	Inversión en salud
Salud	Inversión pública por disciplina científica	91 registros desde 2012	Inversión en investigación médica

Las instituciones de origen que cita el dashboard son DEIS (Ministerio de Salud), RENAPER, INDEC, el presupuesto nacional publicado en datos.gob.ar y el Consejo del Salario.

5. Tratamiento por dominio

5.1 Natalidad y edad de las madres

1. **Selección de variables.** Del archivo de nacimientos por edad de la madre se conservan año, provincia, grupo etario y cantidad. Del archivo departamental, año, provincia y nacimientos.
2. **Agregación provincial.** Se suman las cantidades por provincia y año para obtener la serie que alimenta mapas, rankings y el mapa de calor.
3. **Agregación por edad.** Se suman las cantidades por año y grupo etario de la madre. En la app, el inicio de cada grupo se extrae del texto (por ejemplo, «15-19» pasa a 15) para poder agrupar en tres categorías de trabajo: menores de 20, de 10 a 14 y de 15 a 19, y de 20 o más.
4. **Totales nacionales.** La app calcula el total anual y la variación interanual a partir de la serie provincial. El total que usa el análisis de hitos proviene de esa misma fuente, de modo que todas las secciones del dashboard sean coherentes entre sí.

5. **Exportación.** Se generan, entre otras, las tablas de nacimientos por provincia y año, madres por grupo de edad y madres por provincia, año y grupo de edad.

5.2 Estructura de la población

- Se filtra a personas con **nacionalidad argentina y nacidas en Argentina**, y se separan varones y mujeres. Este universo suma 44.416.608 personas: 21.954.058 varones y 22.462.550 mujeres.
- Las edades quinquenales se convierten en categoría ordenada, de «0 a 4» hasta «100 y +», para que la pirámide respete el orden natural y no el alfabético.
- Los varones se representan con valores negativos para construir la pirámide con barras horizontales espejadas.
- La app deriva de la pirámide tres indicadores: porcentaje de 0 a 14 años, porcentaje de 65 o más y mayores de 65 por cada 100 menores de 15.

5.3 Economía

- **Salario mínimo.** Se ordena por fecha, se recorta de diciembre de 2012 a diciembre de 2024 y se conservan enero y diciembre de cada año. Los valores se mantienen en pesos corrientes. La variación anual se calcula de enero a enero.
- **Inflación.** Se toman los valores desde 2012, se agrupan por año y se capitalizan dentro del año con el producto de (1 + x/100) menos 1. Después se calcula cuánto varió la inflación acumulada respecto de la del año anterior.

5.4 Inversión en salud

- Se leen dos tablas presupuestarias con separador punto y coma, una de ellas con codificación `latin1`, y se descartan columnas vacías.
- Se filtra el objetivo «Salud» y la disciplina «Ciencias Médicas», y se suma por año.
- Las series quedan en millones de pesos corrientes.

5.5 Percepción social

- Los códigos de ola de la encuesta (3, 4 y 5) se reemplazan por los años 2012, 2015 y 2021.
- Se calculan medianas de actitud sobre oportunidades para los hijos, y distribuciones porcentuales de actitud ante la desigualdad e interés por la economía, por ola.
- Estos resultados se exportan como material complementario y todavía no forman parte del relato del dashboard.

6. Normalización y unión entre fuentes

Unir fuentes de distintas instituciones exige reconciliar cómo cada una escribe los nombres de provincias. El proyecto resuelve esto en dos pasos:

- **Corrección de acentos** en la serie de nacimientos (Córdoba, Entre Ríos, Neuquén, Río Negro, Tucumán) para que coincidan con el GeoJSON oficial usado en los mapas.
- **Clave de comparación** (`clave_prov`): se pasa el nombre a minúsculas, se eliminan acentos y se unifican variantes como «Ciudad Autónoma de Buenos Aires», «CABA» y «Capital Federal», y las distintas escrituras de Tierra del Fuego.

Esta clave permite cruzar nacimientos con población y con el mapa sin depender de que el nombre sea idéntico en cada archivo.

7. Indicadores derivados

Indicador	Cálculo	Para qué sirve
Variación interanual	Cambio porcentual respecto del año anterior	Ver ritmo de la caída o recuperación
Año pico y caída desde el pico	Máximo de la serie y variación hasta el último año	Dato central del relato
Índice base 100	Valor de cada año dividido por el del año del hito, por 100	Comparar series de distinta escala
Ritmo anual promedio	(final / inicial) elevado a 1/años, menos 1	Comparar la velocidad de baja antes y después de un hito
Proporción de madres menores de 20	Nacimientos de madres menores de 20 sobre el total anual	Seguir el cambio en la edad de maternidad
Tasa bruta aproximada	Nacimientos de 2024 cada 1.000 habitantes	Comparar provincias entre sí
Nacimientos cada 1.000 mujeres	Nacimientos de 2024 sobre población femenina	Segunda lectura comparativa
Base de la pirámide	Población de 0 a 4 frente a 10 a 14 años	Mostrar el angostamiento de la base

8. Controles de calidad

Controles incorporados al proyecto:

- **Chequeo de coherencia demográfica:** los nacimientos de los últimos cinco años se comparan con el grupo de 0 a 4 años de la pirámide. El dashboard muestra la diferencia porcentual y la usa para validar que ambas fuentes cuenten una historia consistente.
- **Validación de archivos:** la app avisa qué notebook ejecutar cuando falta un archivo procesado, en lugar de fallar sin explicación.
- **Mapa con respaldo:** si no se puede descargar el GeoJSON de provincias, se usa una copia local y, si tampoco existe, el resto del dashboard sigue funcionando.

Puntos ya corregidos en la aplicación: rutas multiplataforma, funciones de formato unificadas, signo de los porcentajes (las proporciones ya no aparecen con «+») y total de nacimientos tomado de una única fuente.

Puntos pendientes en los notebooks, con su impacto:

Tema	Riesgo	Acción recomendada
Definición de la serie de inflación (el archivo se llama «interanual» pero se capitaliza como mensual)	Podría sobreestimar la inflación anual	Confirmar la definición en la fuente; si es interanual, usar el valor de diciembre
Series de inversión en pesos corrientes	La suba puede reflejar solo inflación	Deflactar o expresar como porcentaje del presupuesto
Código 99 en la escala de oportunidades para los hijos	Distorsiona la mediana	Excluir códigos de «no sabe/no contesta» y usar ponderadores
Filtro de ola aplicado después del reemplazo de códigos	No filtra nada	Filtrar antes del reemplazo
Filtro por texto con codificación dañada («Ciencias Médicas»)	Puede devolver vacío en otro entorno	Leer con `latin1` y normalizar el texto
Etiqueta «Diciembre» en un gráfico calculado con enero	Lectura confusa	Corregir etiqueta o criterio

---

Parte II · Storytelling

9. Enfoque narrativo

El dashboard no se limita a mostrar gráficos: cuenta una historia con principio, desarrollo y cierre. Tres decisiones definen su enfoque.

1. Empezar por un dato, no por un método. El relato abre con una comparación simple y fuerte: cuántos nacimientos se registraron en el año pico y cuántos en el último año, con la variación porcentual entre ambos. Es una cifra que cualquier persona entiende en segundos.

2. Ir de lo general a lo particular. Primero la serie nacional, luego el año a año, después las provincias, más tarde la edad de las madres y, al final, el contexto y las hipótesis. Cada capítulo responde la pregunta que dejó abierta el anterior.

3. Ser prudente con las causas. El tono es descriptivo. Cada vez que el relato roza una explicación, aparece una nota que aclara que se trata de una asociación y qué evidencia haría falta para afirmar más.

10. Arco narrativo en ocho capítulos

Cap.	Título	Mensaje	Recurso visual
01	El dato que cambia la historia	Hay menos nacimientos hoy que en el año pico	Dos cifras grandes con una flecha y la variación en un recuadro destacado
02	El descenso no ocurrió de golpe	La caída tiene un ritmo propio, con años más fuertes que otros	Línea de la serie anual y barras de variación, coral cuando baja y verde azulado cuando sube
03	Año a año	Qué cambió entre un año y el anterior	Selector de año, diferencia absoluta, provincia con mayor suba y mayor baja, donas de provincias en alza y a la baja
04	Argentina no es una sola realidad	La tendencia nacional convive con diferencias territoriales	Ranking, mapa de calor histórico y mapa coroplético

Cap.	Título	Mensaje	Recurso visual
05	La edad de las madres	Cambia cuándo se tienen hijos	Donas comparando el primer y el último año, y línea de la proporción de madres menores de 20
06	El contexto económico y de salud	Qué pasaba en paralelo	Inflación, salario mínimo e inversión en salud, siempre contra la serie de nacimientos en un segundo eje
07	¿Por qué baja? ¿Por qué importa?	Qué hipótesis tienen respaldo y cuáles quedan abiertas	Composición por edad, cruce con población y pirámide poblacional
08	Conclusiones y fuentes	Qué nos cuenta la evidencia	Tarjetas de conclusiones, fuentes y pregunta para el debate

Un detalle de oficio: en el capítulo 6 la serie de nacimientos se dibuja con línea punteada sobre el eje derecho y el texto aclara que las series se muestran juntas «para dar contexto, no para afirmar causas». Superponer curvas sin esa aclaración invita a ver correlaciones donde puede no haberlas.

11. Los cuatro hitos: una historia dentro de la historia

La sección «Posibles causas» propone mirar qué ocurrió con los nacimientos después de cuatro medidas de salud sexual y reproductiva. Cada hito es un pequeño capítulo con la misma estructura: **qué pasó**, **hipótesis**, **gráfico** e **indicadores**. Usar siempre el mismo molde permite comparar hitos sin esfuerzo.

Hito	Qué ocurrió	Hipótesis que se evalúa	Serie observada
2014 · Implante subdérmico	Se incorpora a la canasta gratuita, con prioridad para adolescentes de 15 a 19 años sin obra social que ya tuvieron un evento obstétrico	Un método de larga duración, que no depende de la adherencia diaria, reduciría nuevos embarazos adolescentes	Madres de 15 a 19 años frente a madres de 20 o más

Hito	Qué ocurrió	Hipótesis que se evalúa	Serie observada
2015 · Autonomía progresiva y Ni Una Menos	Entra en vigencia el nuevo Código Civil y Comercial, que reconoce desde los 13 años decisiones sobre tratamientos no invasivos, y nace Ni Una Menos	Más autonomía para consultar y mayor demanda de educación sexual y consentimiento	Madres de 10 a 14 años frente a otros grupos
2017 · Plan ENIA	Se diseña el Plan Nacional de Prevención del Embarazo No Intencional en la Adolescencia y se implementa desde 2018 con asesorías en escuelas secundarias	Llevar profesionales de salud a la escuela facilita el acceso real a los métodos	Madres menores de 20 años, y comparación entre provincias del plan y el resto, sin Buenos Aires
2020 · Ley 27.610	Sancionada el 30 de diciembre de 2020 y vigente desde enero de 2021	Podría haber reducido nacimientos de embarazos no intencionales	Nacimientos totales, con referencia a menores de 20 y a mayores de 20

Cómo se lee cada gráfico. Todas las series se llevan a base 100 en el año del hito y se muestran hasta tres años antes como contexto. Tres indicadores acompañan el gráfico: cuánto cambió la serie principal hasta 2024, cuánto cambió el grupo de referencia y cómo se compara el ritmo anual de baja antes y después.

Matices que el relato incluye a propósito:

- En el caso de 2014, la serie adolescente venía estable o en alza y el quiebre aparece desde el año siguiente.
- En 2015, los datos agrupan edades de a cinco años, por lo que no se pueden aislar las madres de 13 años en adelante. Además, las cifras son pequeñas y la curva es irregular.
- En 2017, la baja ya estaba en marcha antes del plan, y las provincias del plan partían de tasas más altas, lo que puede inflar su caída relativa.
- En 2020, los nacimientos de ese año corresponden a embarazos casi todos anteriores a la ley, y el descenso general comenzó años antes.

12. Decisiones de diseño al servicio del relato

- **Color con significado.** Coral para bajas y verde azulado para subas; amarillo para destacar hitos y cifras clave; azul para series de referencia. El lector aprende el código sin leer una leyenda.
- **Números grandes.** Las cifras centrales se muestran como «números héroe», con una etiqueta breve que las explica.
- **Interactividad con propósito.** El selector de año permite que cada persona explore el momento que le interesa sin perder el hilo.
- **Varias miradas al mismo dato.** El territorio se ofrece como ranking, mapa de calor y mapa, porque cada formato responde una pregunta distinta (quién es mayor, cómo evolucionó, dónde está).
- **Cierre con una pregunta.** La conclusión termina con una pregunta para el debate sobre qué políticas y servicios deberían adaptarse a un país con menos nacimientos.
- **Fondo ilustrado por período.** El dashboard puede cambiar la imagen de fondo según el año seleccionado (2012–2014, 2015–2018, 2019–2023 y 2024). Por los nombres de los archivos, parecen remitir a períodos de gobierno; conviene explicitar el criterio o mantener el fondo neutro en presentaciones formales, para evitar lecturas políticas que el análisis no busca.

13. Cómo se evita sobreinterpretar

El proyecto aplica una disciplina que lo distingue de un tablero meramente ilustrativo:

1. **Notas junto a cada gráfico** que explican qué muestra y qué no.
2. **Lenguaje condicional** en las hipótesis («podría», «a evaluar»).
3. **Bloque «Qué faltaría para afirmar causas»:** series por edad simple, tasas de fecundidad, comparación ajustada por nivel inicial entre provincias con y sin plan, y datos de abortos y anticoncepción.
4. **Fuentes explícitas** al pie de cada sección, incluyendo referencias externas de verificación sobre la relación entre natalidad y la ley 27.610.
5. **Valores nominales aclarados:** las series monetarias llevan una nota que advierte que el aumento en pesos corrientes no implica mayor poder de compra.

14. Guion sugerido para presentar el proyecto (cinco minutos)

1. **Apertura (30 s).** Mostrar las dos cifras del capítulo 1 y la variación entre el año pico y el último año. «Argentina registra menos nacimientos que hace una década».
2. **El ritmo (45 s).** Mostrar la serie anual y señalar el año de mayor variación.

3. **El territorio (60 s).** Cambiar entre ranking y mapa y marcar que la baja no es uniforme.
4. **La edad (45 s).** Comparar las donas de madres menores de 20 entre el primer y el último año.
5. **El contexto (45 s).** Mostrar una de las series económicas y repetir la frase clave: contexto, no causa.
6. **Los hitos (60 s).** Elegir uno (por ejemplo el Plan ENIA) y leer el gráfico de provincias del plan frente al resto, con sus matices.
7. **Cierre (15 s).** Leer la pregunta para el debate.

15. Limitaciones y trabajo futuro

Limitaciones:

- No hay inferencia causal; las comparaciones son antes y después con referencias simples.
- Se usan cantidades y no tasas de fecundidad por edad.
- La población es de un único momento (agosto de 2024) y solo incluye argentinos nacidos en el país, lo que sesga las tasas en provincias con mucha migración.
- Las series monetarias están en pesos corrientes.
- El mapa depende de un servicio externo, aunque ahora cuenta con respaldo local.

Próximos pasos:

1. Resolver los pendientes de la tabla de la sección 8, empezando por la serie de inflación y la deflactación de las inversiones.
2. Incorporar tasas específicas de fecundidad con población proyectada por año.
3. Evaluar el Plan ENIA con un diseño de diferencias en diferencias, ajustando por el nivel inicial de cada provincia.
4. Integrar la encuesta de percepción al relato, usando ponderadores.
5. Sumar variables socioeconómicas por provincia.
6. Agregar pruebas automáticas sobre los archivos procesados (columnas esperadas, rango de años y totales).

16. Conclusión

El valor del proyecto está en la combinación de dos cualidades poco frecuentes juntas: un tratamiento de datos ordenado y trazable, que separa preparación y visualización, y una narrativa que guía al lector sin prometer más de lo que la evidencia permite. La historia

que cuenta es clara: hay menos nacimientos que hace una década, el cambio no es uniforme en el territorio, la edad de las madres se desplazó y existen hipótesis razonables pero todavía no probadas sobre las causas.

Con los ajustes pendientes en los notebooks, el proyecto queda en condiciones de presentarse como un análisis exploratorio sólido de la transformación demográfica argentina reciente.

Anexo · Archivos procesados que alimentan el dashboard

Carpeta	Archivo	Contenido
`POBLACION`	`nacimientos_total_año.csv`	Nacimientos totales por año (departamental)
`POBLACION`	`nacimientos_provi_año.csv`	Nacimientos por provincia y año
`POBLACION`	`madres_grupo_edad_total.csv`	Nacimientos por año y grupo de edad de la madre
`POBLACION`	`madres_provincia_grupo_edad.csv`	Nacimientos por provincia, año y grupo de edad
`POBLACION`	`poblacion_no_extranjera_edad_m.csv` y `_f.csv`	Población argentina por provincia, varones y mujeres
`POBLACION`	`piramide_poblacion.csv`	Población por edad quinquenal y sexo
`POBLACION`	`percepcion_*.csv`	Cuatro tablas de percepción social
`ECONOMIA`	`salario_min_desde_2012.csv` y `variacion_salario_min_desde_2012.csv`	Salario mínimo y su variación
`ECONOMIA`	`inflacion_2012_2024.csv` y `variacion_inflacion_2012_2024.csv`	Inflación acumulada anual y su variación
`SALUD`	`inversion_salud_año.csv` y `inversion_investigacion_salud_año.csv`	Inversión anual en salud y en investigación médica